Informe de resultados prueba técnica Quind

Aspirante: David Armando Ruiz Lugo

Análisis exploratorio de datos

Se recibió la base de datos Films2.xlsx, con el fin de realizar el proceso de ETL con Python y PySpark.

1. Identificar las dimensiones de las tablas

```
Dimensiones Store: (2, 4)
Dimensiones Customer: (1392, 11)
Dimensiones Rental: (16044, 7)
Dimensiones Inventory: (4581, 4)
Dimensiones Film: (1003, 14)
```

2. Validación de los datos imputados

Al realizar el análisis exploratorio fue posible identificar inconsistencias en la imputación de datos y en los nombres de las columnas de las diferentes tablas del archivo Films 2.xlsx, como se puede apreciar a continuación.

```
print(df_customer.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1392 entries, 0 to 1391
Data columns (total 11 columns):
 #   Column            Non-Null Count  Dtype
---  ------            --------------  -----
 0   customer_id       1392 non-null   int64
 1    store_id         1392 non-null   int64
 2    first_name       1392 non-null   object
 3    last_name        1392 non-null   object
 4    email            1392 non-null   object
 5    address_id       1392 non-null   int64
 6    active           1392 non-null   int64
 7    create_date      1392 non-null   object
 8    last_update      1392 non-null   object
 9    customer_id_old  1392 non-null   object
 10   segment          1392 non-null   object
dtypes: int64(4), object(7)
```

```
print(df_film.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1003 entries, 0 to 1002
Data columns (total 14 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   film_id               1003 non-null   object
 1    title                1003 non-null   object
 2    description          1003 non-null   object
 3    release_year         1003 non-null   object
 4    language_id          1003 non-null   int64
 5    original_language_id 1003 non-null   object
 6    rental_duration      1003 non-null   int64
 7    rental_rate          1003 non-null   object
 8    length               1003 non-null   object
 9    replacement_cost     1003 non-null   object
 10   num_voted_users      1003 non-null   object
 11   rating               1003 non-null   object
 12   special_features     1003 non-null   object
 13  last_update           1003 non-null   object
dtypes: int64(2), object(12)
```

Inconsistencias encontradas

- Nombres de las columnas con espacios adicionales
- Valores de features con caracteres alfanuméricos y espacios adicionales
- Valores nulos no reconocidos por el intérprete

Debido a la irregularidad de las tablas se procede a limpiarlas todas en pro de eliminar cualquier posible error. Esto con ayuda de las funciones

```
print(df_film.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1003 entries, 0 to 1002
Data columns (total 14 columns):
 #   Column                Non-Null Count  Dtype
---  ------                --------------  -----
 0   film_id               1003 non-null   int64
 1   title                 1003 non-null   object
 2   description           1003 non-null   object
 3   release_year          1003 non-null   int64
 4   language_id           1003 non-null   int64
 5   original_language_id  0 non-null      float64
 6   rental_duration       1003 non-null   int64
 7   rental_rate           1003 non-null   float64
 8   length                1003 non-null   int64
 9   replacement_cost      1003 non-null   float64
 10  num_voted_users       1003 non-null   int64
 11  rating                1003 non-null   object
 12  special_features      1003 non-null   object
 13  last_update           1003 non-null   object
dtypes: float64(3), int64(6), object(5)
```

```
print(df_customer.info())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1392 entries, 0 to 1391
Data columns (total 11 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   customer_id      1392 non-null   int64
 1   store_id         1392 non-null   int64
 2   first_name       1392 non-null   object
 3   last_name        1391 non-null   object
 4   email            1392 non-null   object
 5   address_id       1392 non-null   int64
 6   active           1392 non-null   int64
 7   create_date      1392 non-null   object
 8   last_update      1392 non-null   object
 9   customer_id_old  793 non-null    object
 10  segment          793 non-null    object
dtypes: int64(4), object(7)
```

Como se puede observar las inconsistencias han sido eliminadas, esto se evidencia en el conteo de valores no nulos, el nombre de las columnas y el formato de las mismas.
Nota: Debido al tamaño del informe solo se muestra la info de 2 tablas, pero se filtraron las 5.

3. Análisis de datos:
    a. Clientes que más rentan películas y películas más rentadas.

Frecuencia de clientes

	customer_id	frecuencia
0	148	46
1	526	45
2	144	42
3	236	42
4	75	41
..	...	...
594	248	15
595	110	14
596	61	14
597	281	14
598	318	12

[599 rows x 2 columns]

Frecuencia películas rentadas

	inventory_id	frecuencia
0	4581	5
1	1083	5
2	1113	5
3	1111	5
4	2897	5
...	...	...
4575	3214	2
4576	2786	1
4577	2662	1
4578	1580	1
4579	3372	1

[4580 rows x 2 columns]

Se puede observar que todos los clientes han rentado películas en múltiples ocasiones y que ninguna película ha sido rentada más de 5 veces.

    b. Películas rentadas por tienda

Frecuencia películas rentadas por tienda

	staff_id	frecuencia
0	1	8040
1	2	8004

Se observa que el número de películas rentadas por tienda es muy similar.

    c. Distribución de la duración de renta de las películas, para lo cual se restando la columna return_date - rental_date.

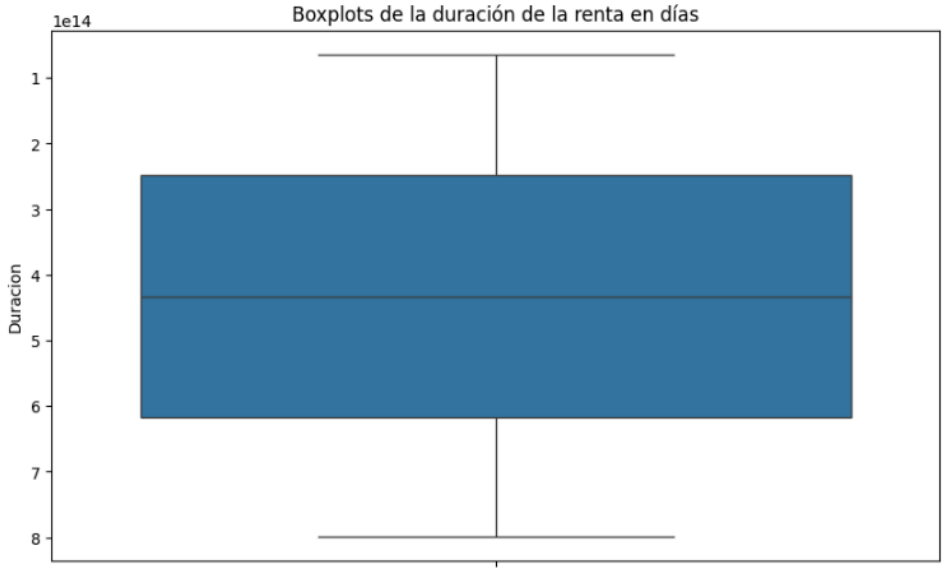

Esquema de aplicación propuesto

```
etl_pyspark_project/
└── etl_project/
    ├── __init__.py             # Archivo de inicialización del paquete principal
    ├── config/
    │   ├── __init__.py         # Para convertir 'config' en un módulo
    │   └── config.py           # Configuración de rutas y variables globales
    ├── extract/
    │   ├── __init__.py         # Para convertir 'extract' en un módulo
    │   └── extract_data.py     # Código de extracción de datos
    ├── load/
    │   ├── __init__.py         # Para convertir 'load' en un módulo
    │   └── load_data.py        # Código de carga de datos
    ├── transform/
    │   ├── __init__.py         # Para convertir 'transform' en un módulo
    │   └── transform_data.py   # Código de transformación de datos
    ├── utils/
    │   ├── __init__.py         # Para convertir 'utils' en un módulo
    │   └── spark_session.py    # Código para crear la sesión de Spark
    └── main.py                 # Archivo principal para ejecutar el ETL
```

En el archivo readme del repositorio encontrará más detalles acerca de la construcción de la app propuesta.

Preguntas de negocio

1. ¿Cuál es la distribución del tiempo promedio de renta por meses del año?
2. ¿Cuál es la distribución de special_features por meses del año?
3. Correlación entre rental_duration y replacement_cost
4. Distribución de customer[“address_id”] y rental[“rental_duration”]
5. Cuales son las zonas de influencia de cada tienda, (se deben cruzar las tablas: customer, rental e inventory.

Nota 1: Es conveniente enriquecer la data con la edad de los clientes
Nota 2: Es conveniente enriquecer la data con las categorías de las películas rentadas.

Conclusiones:

- La base de datos presentada contiene muchas inconsistencias tanto en la imputación, como en el nombre de las columnas, por lo que es conveniente limpiar y transformar todas las columnas de todas las tablas para evitar datos corruptos.
- Para realizar un análisis que permita la toma de decisión, es necesario realizar varios cruces entre tablas con el fin de exponer patrones y comportamiento de los usuarios y películas, así como de las tiendas.
- Si bien la data suministrada nos da información sobre todos los actores involucrados en el modelo de negocio, es necesario enriquecer los datos con el fin de entender mejor el patrón de comportamiento de los usuarios.
- Debido a la gran cantidad de información lo más recomendable es trabajar estos datos con el framework de procesamiento de datos PySpark, dado que gracias a sus cualidades es posible distribuir las cargas y atender a las solicitudes de estas 2 o más tiendas.